

Algorithmen und Wahrscheinlichkeit

Nicola Studer

nicstuder@student.ethz.ch

18. Juni 2022

1 Graphen

1.1 Terminologie

- K_n := Vollständiger Graph mit n Knoten
- C_n := Kreisgraph mit n Knoten
- P_n := Pfad mit n Knoten
- H_d := d -dimensionaler Hyperwürfel
- Hamiltonkreis := Ein Kreis in G , der jeden Knoten genau einmal enthält. $\mathcal{O}(n^2 2^n)$
- Eulertour := Ein geschlossener Weg in G , der jede Kante genau einmal enthält

1.2 Zusammenhang

Def 1.23 (k -zusammenhängend). Ein Graph $G = (V, E)$ heisst k -zusammenhängend, falls $|V| \geq k + 1$ und für alle Teilmengen $X \subseteq V$ mit $|X| < k$ gilt: Der Graph $G[V \setminus X]$ ist zusammenhängend.

Def 1.24 (k -kanten-zusammenhängend). Ein Graph $G = (V, E)$ heisst k -kanten-zusammenhängend, falls für alle Teilmengen $X \subseteq E$ mit $|X| < k$ gilt: Der Graph $(V, E \setminus X)$ ist zusammenhängend.

Satz 1.25 (Menger). Sei $G = (V, E)$ ein Graph. Dann gilt:

- G ist k -zusammenhängend $\iff \forall u, v \in V, u \neq v$ gibt es k intern-knotendiskunkte u - v -Pfade
- G ist k -kanten-zusammenhängend $\iff \forall u, v \in V, u \neq v$ gibt es k kantendisjunkte u - v -Pfade

Bmk.. (Knoten-) Zusammenhang \leq Kanten-Zusammenhang \leq minimaler Grad

Bmk. (low-Werte).

$$\text{low}[v] = \min \left(\text{dfs}[v], \min_{(v,w) \in E} \begin{cases} \text{dfs}[v] & \text{if } (v,w) \text{ rest-edge} \\ \text{low}[w] & \text{if } (v,w) \text{ tree-edge} \end{cases} \right)$$

Artikulationsknoten. Sei $G = (V, E)$ ein zusammenhängender Graph. $v \in V$ Artikulationsknoten $\iff G[V \setminus \{v\}]$ nicht zusammenhängend. Artikulationsknoten, wenn:

1. $v \neq \text{root}$ und v hat Kind u im DFS-Baum mit $\text{low}[u] \geq \text{dfs}[v]$
2. $v = \text{root}$ und v hat mindestens zwei Kinder im DFS-Baum.

Brücken. $e \in E$ Brücke $\iff G - e$ nicht zusammenhängend. Eine Baumkante $e = (v, w) \in E$ ist genau dann eine Brücke, wenn $\text{low}[w] > \text{dfs}[v]$. Restkanten sind niemals Brücken.

Lemma. Sei $G = (V, E)$ ein zusammenhängender Graph. Ist $\{x, y\} \in E$ eine Brücke so gilt: $\deg(x) = 1$ oder x ist Artikulationsknoten.

Satz 1.28. Für zusammenhängende Graphen $G = (V, E)$, die mit Adjazenzlisten gespeichert sind, kann man in Zeit $\mathcal{O}(|E|)$ alle Artikulationsknoten und Brücken berechnen.

Def 1.29. Sei $G = (V, E)$ ein zusammenhängender Graph. Für $e, f \in E$ definieren wir eine Äquivalenzrelation durch:

$$e \sim f : \iff e \begin{cases} e = f, & \text{oder} \\ \exists \text{Kreis durch } e \text{ und } f \end{cases}$$

1.3 Kreise

Satz 1.31. Ein zusammenhängender Graph $G = (V, E)$ enthält eine Eulertour \iff der Grad jedes Knotens gerade ist. Die Tour kann man in $\mathcal{O}(|E|)$ Zeit finden.

Satz 1.32. Seien $m, n \geq 2$. Ein $n \times m$ Gitter enthält einen Hamiltonkreis $\iff n \cdot m$ gerade ist.

Satz 1.40 (Dirac 1952). Jeder Graph $G = (V, E)$ mit $|V| \geq 3$ und Minimalgrad $\delta(G) \geq \frac{|V|}{2}$ enthält einen Hamiltonkreis.

Für das METRISCHE TRAVELING SALESMAN PROBLEM gibt es einen 2-Approximationsalgorithmus mit Laufzeit $\mathcal{O}(n^2)$.

1.4 Matchings

Matching. Eine Kantenmenge $M \subseteq E$ heisst Matching in einem Graphen $G = (V, E)$, falls kein Knoten des Graphen zu mehr als einer Kante aus M inzident ist.

$$e \cap f = \emptyset \text{ für alle } e, f \in M \text{ mit } e \neq f$$

Ein Knoten wird von M überdeckt, falls es eine Kante $e \in M$ gibt, die v enthält.

Perfektes Matching. Ein Matching M heisst perfektes Matching, wenn jeder Knoten durch genau eine Kante aus M überdeckt wird, oder, anders ausgedrückt, wenn $M = \frac{|V|}{2}$

Matching Typen.

- M heisst inklusionsmaximal, falls gilt $M \cup \{e\}$ ist kein Matching für alle Kanten $e \in E \setminus M$.
- M heisst kardinalitätsmaximal, falls gilt $|M| \geq |M'|$ für alle Matchings M' in G .

Satz 1.47. Der Algorithmus GREEDY-MATCHING bestimmt in Zeit $\mathcal{O}(|E|)$ ein inklusionsmaximales Matching M_{Greedy} für das gilt:

$$|M_{\text{Greedy}}| \geq \frac{1}{2} |M_{\text{max}}|$$

wobei M_{max} ein kardinalitätsmaximales Matching sei.

Augmentierender Pfad. Ein M -augmentierender Pfad ist ein Pfad, der abwechselnd Kanten aus M und nicht aus M enthält und der in von M nicht überdeckten Knoten beginnt und endet.

\implies durch tauschen entlang M können wir das Matching verbessern.

Satz 1.48 (Berge). Ist M ein Matching in einem Graphen $G = (V, E)$, das nicht kardinalitätsmaximal ist, so existiert ein augmentierender Pfad zu M .

Satz 1.51. Für das METRISCHE TRAVELLING SALESMAN PROBLEM gibt es einen 3/4-Approximationsalgorithmus mit Laufzeit $\mathcal{O}(n^3)$ mit MST, Matching und Eulertour.

Satz 1.52 (Hall, Heiratssatz). Ein bipartiter Graph $G = (A \uplus B, E)$ enthält ein Matching M der Kardinalität $|M| = |A| \iff \forall X \subseteq A (|X| \leq |N(X)|)$

Cor (Frobenius). Für alle k gilt: Jeder k -reguläre bipartite Graph enthält ein perfektes Matching.

1.5 Färbungen

Def 1.56. Eine Färbung eines Graphen $G = (V, E)$ mit k Farben ist eine Abbildung $c : V \rightarrow [k]$, so dass gilt

$$c(u) \neq c(v) \quad \text{für alle Kanten } \{u, v\} \in E$$

Die chromatische Zahl $\chi(G)$ ist die minimale Anzahl Farben, die für eine Knotenfärbung von G benötigt wird.

$$\chi(G) \leq k \iff G \text{ } k\text{-partit}$$

Satz 1.58. Ein Graph $G = (V, E)$ ist genau dann bipartit, wenn er keinen Kreis ungerader Länge als Teilgraphen enthält.

Satz 1.59 (Vierfarbensatz). Jede Landkarte lässt sich mit vier Farben färben.

- Bmk..**
- Die Heuristik findet immer eine Färbung mit 2 Farben für Bäume
 - ist ein Graph planar (Kann überkreuzungsfrei in der Ebene gezeichnet werden), so gibt es immer einen Knoten vom Grad ≤ 5 .
 - Die Heuristik findet eine Färbung mit ≤ 6 Farben für planare Graphen
 - $G = (V, E)$ zshgd. und es gibt $v \in V$ mit $\deg(v) < \Delta(G)$. Heuristik (Breiten/Tiefensuche) liefert Reihenfolge, für die der Greedy-Algorithmus höchstens $\Delta(G)$ Farben benötigt.

Satz 1.60. Sei G ein zusammenhängender Graph. Für die Anzahl Farben $C(G)$, die der Algorithmus GREEDY-FÄRBUNG benötigt, um die Knoten des Graphen G zu färben, gilt

$$\chi(G) \leq C(G) \leq \Delta(G) + 1$$

ist der Graph als Adjazenzliste gespeichert, findet der Algorithmus die Färbung in Zeit $\mathcal{O}(|E|)$

Cor. Ist G ein Graph, in dem man jeden Block mit k Farben färben kann, dann kann man auch G mit k Farben färben.

Theorem. $\forall k \in \mathbb{N}, \forall r \in \mathbb{N}$: es gibt Graphen ohne einen Kreis mit Länge $\leq k$, aber mit chromatischer Zahl $\geq r$.

Satz 1.64 (Brooks). Ist $G = (V, E)$ ein zusammenhängender Graph, $G \neq K_n, G \neq C_{2n+1}$, so gilt:

$$\chi(G) \leq \Delta(G)$$

und es gibt einen Algorithmus, der die Knoten des Graphen in Zeit $\mathcal{O}(|E|)$ mit $\delta(G)$ Farben färbt.

Satz 1.66 (Mycielski-Konstruktion). Für alle $k \geq 2$ gibt es einen dreiecksfreien Graphen G_k mit $\chi(G_k) \geq k$.

Satz 1.67. Einen 3-färbbaren Graphen kann man in Zeit $\mathcal{O}(|V| + |E|)$ mit $\mathcal{O}(\sqrt{|V|})$ Farben färben.

2 Wahrscheinlichkeit Theorie

Def 2.1. Ein diskreter Wahrscheinlichkeitsraum ist bestimmt durch eine Ergebnismenge $\Omega = \{\omega_1, \omega_2, \dots\}$ von Elementarereignissen. Jedem Elementarereignis ω_i ist eine Wahrscheinlichkeit $\Pr[\omega_i]$ zugeordnet, wobei wir fordern, dass $0 \leq \Pr[\omega_i] \leq 1$ und $\sum_{\omega \in \Omega} \Pr[\omega] = 1$. Eine Menge $E \subseteq \Omega$ heisst Ereignis. Die Wahrscheinlichkeit $\Pr[E]$ eines Ereignisses ist definiert durch $\Pr[E] := \sum_{\omega \in E} \Pr[\omega]$. Ist E ein Ereignis, so bezeichnen wir mit $\bar{E} := \Omega \setminus E$ das Komplementärereignis zu E .

Lemma 2.2. Für Ereignisse A, B gilt:

1. $\Pr[\emptyset] = 0, \Pr[\Omega] = 1$
2. $0 \leq \Pr[A] \leq 1$
3. $\Pr[\bar{A}] = 1 - \Pr[A]$
4. Wenn $A \subseteq B$, so folgt $\Pr[A] \leq \Pr[B]$

Satz 2.3 (Additionssatz). Wenn A_1, \dots, A_n paarweise disjunkte Ereignisse sind, so gilt

$$\Pr \left[\bigcup_{i=1}^n A_i \right] = \sum_{i=1}^n \Pr[A_i]$$

Für eine unendliche Menge von disjunkten Ereignissen A_1, A_2, \dots gilt analog

$$\Pr \left[\bigcup_{i=1}^{\infty} A_i \right] = \sum_{i=1}^{\infty} \Pr[A_i]$$

Satz 2.5 (Siebformel). Für Ereignisse A_1, \dots, A_n ($n \geq 2$) gilt:

$$\begin{aligned} \Pr \left[\bigcup_{i=1}^n A_i \right] &= \sum_{l=1}^n (-1)^{l+1} \sum_{1 \leq i_1 < \dots < i_l \leq n} \Pr[A_{i_1} \cap \dots \cap A_{i_l}] \\ &= \sum_{i=1}^n \Pr[A_i] - \sum_{i \leq i_1 < i_2 \leq n} \Pr[A_{i_1} \cap A_{i_2}] \\ &\quad + \sum_{1 \leq i_1 < i_2 < i_3 \leq n} \Pr[A_{i_1} \cap A_{i_2} \cap A_{i_3}] - \dots \\ &\quad + (-1)^{n+1} \Pr[A_1 \cap \dots \cap A_n] \end{aligned}$$

Cor 2.6 (Boolsche Ungleichung). Für Ereignisse A_1, \dots, A_n gilt:

$$\Pr \left[\bigcup_{i=1}^n A_i \right] \leq \sum_{i=1}^n \Pr[A_i]$$

Analog gilt für eine unendliche Folge von Ereignissen A_1, A_2, \dots , dass $\Pr[\bigcup_{i=1}^{\infty} A_i] \leq \sum_{i=1}^{\infty} \Pr[A_i]$.

Def 2.8. A und B seien Ereignisse mit $\Pr[B] > 0$. Die bedingte Wahrscheinlichkeit $\Pr[A|B]$ von A gegeben B ist definiert durch

$$\Pr[A|B] := \frac{\Pr[A \cap B]}{\Pr[B]}$$

Satz 2.10 (Multiplikationssatz). Seien die Ereignisse A_1, \dots, A_n gegeben. Falls $\Pr[A_1 \cap \dots \cap A_n] > 0$ ist, gilt

$$\Pr[A_1 \cap \dots \cap A_n] = \Pr[A_1] \cdot \Pr[A_2|A_1] \cdot \dots \cdot \Pr[A_n|A_1 \cap \dots \cap A_{n-1}]$$

Satz 2.13 (Totale Wahrscheinlichkeit). Die Ereignisse A_1, \dots, A_n seien paarweise diskunkt und es gelte $B \subseteq A_1 \cup \dots \cup A_n$. Dann folgt

$$\Pr[B] = \sum_{i=1}^n \Pr[B|A_i] \cdot \Pr[A_i]$$

Analog gilt für paarweise disjunkte Ereignisse A_1, A_2, \dots mit $B \subseteq \bigcup_{i=1}^{\infty} A_i$, dass

$$\Pr[B] = \sum_{i=1}^{\infty} \Pr[B|A_i] \cdot \Pr[A_i]$$

Satz 2.15 (Bayes). Die Ereignisse A_1, \dots, A_n seien paarweise disjunkt. Ferner sei $B \subseteq A_1 \cup \dots \cup A_n$ ein Ereignis mit $\Pr[B] > 0$. Dann gilt für ein beliebiges $i = 1, \dots, n$

$$\Pr[A_i|B] = \frac{\Pr[A_i \cap B]}{\Pr[B]} = \frac{\Pr[B|A_i] \cdot \Pr[A_i]}{\sum_{j=1}^n \Pr[B|A_j] \cdot \Pr[A_j]}$$

Analog gilt für paarweise disjunkte Ereignisse A_1, A_2, \dots mit $B \subseteq \bigcup_{i=1}^{\infty} A_i$, dass

$$\Pr[A_i|B] = \frac{\Pr[A_i \cap B]}{\Pr[B]} = \frac{\Pr[B|A_i] \cdot \Pr[A_i]}{\sum_{j=1}^{\infty} \Pr[B|A_j] \cdot \Pr[A_j]}$$

Def 2.18. Die Ereignisse A und B heissen unabhängig, wenn gilt $\Pr[A \cap B] = \Pr[A] \cdot \Pr[B]$

Def 2.22. Die Ereignisse A_1, \dots, A_n heissen unabhängig, wenn für alle Teilmengen $I \subseteq \{1, \dots, n\}$ mit $I = \{i_1, \dots, i_k\}$ gilt, dass

$$\Pr[A_{i_1} \cap \dots \cap A_{i_k}] = \Pr[A_{i_1}] \cdot \dots \cdot \Pr[A_{i_k}]$$

Eine unendliche Familie von Ereignissen A_i mit $i \in \mathbb{N}$ heisst unabhängig, wenn die Gleichung für jede endliche Teilmenge $I \subseteq \mathbb{N}$ erfüllt ist.

Lemma 2.23. Die Ereignisse A_1, \dots, A_n sind genau dann unabhängig, wenn für alle $(s_1, \dots, s_n) \in \{0, 1\}^n$ gilt, dass

$$\Pr[A_1^{s_1} \cap \dots \cap A_n^{s_n}] = \Pr[A_1^{s_1}] \cdot \dots \cdot \Pr[A_n^{s_n}]$$

wobei $A_i^0 = \bar{A}_i$ und $A_i^1 = A_i$.

Lemma 2.24. Seien A , B und C unabhängige Ereignisse. Dann sind auch $A \cap B$ und C bzw. $A \cup B$ und C unabhängig.

Def 2.25. Eine Zufallsvariable ist eine Abbildung $X : \Omega \rightarrow \mathbb{R}$, wobei Ω die Ergebnismenge eines Wahrscheinlichkeitsraum ist.

Dichtefunktion.

$$f_X : \mathbb{R} \rightarrow [0, 1], \quad x \mapsto \Pr[X = x]$$

Verteilungsfunktion.

$$F_X : \mathbb{R} \rightarrow [0, 1], \quad x \mapsto \Pr[X \leq x] = \sum_{x' \in W_X : x' \leq x} \Pr[X = x']$$

Def 2.27. Zu einer Zufallsvariable X definieren wir den Erwartungswert $\mathbb{E}[X]$ durch

$$\mathbb{E}[X] := \sum_{x \in W_X} x \cdot \Pr[X = x]$$

sofern die Summe absolut konvergiert. Ansonsten sagen wir, dass der Erwartungswert undefiniert ist.

Lemma 2.29. Ist X eine Zufallsvariable, so gilt:

$$\mathbb{E}[X] = \sum_{\omega \in \Omega} X(\omega) \cdot \Pr[\omega]$$

Satz 2.30. Sei X eine Zufallsvariable mit $W_X \subseteq \mathbb{N}_0$. Dann gilt

$$\mathbb{E}[X] = \sum_{i=1}^{\infty} \Pr[X \geq i]$$

Satz 2.32. Sei X eine Zufallsvariable. Für paarweise disjunkte Ereignisse A_1, \dots, A_n mit $A_1 \cup \dots \cup A_n = \Omega$ und $\Pr[A_1], \dots, \Pr[A_n] > 0$ gilt

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[X|A_i] \cdot \Pr[A_i]$$

Für paarweise disjunkte Ereignisse A_1, A_2, \dots mit $\bigcup_{i=1}^{\infty} A_k = \Omega$ und $\Pr[A_1], \Pr[A_2], \dots > 0$ gilt analog

$$\mathbb{E}[X] = \sum_{i=1}^{\infty} \mathbb{E}[X|A_i] \cdot \Pr[A_i]$$

Satz 2.33 (Linearität des Erwartungswerts). Für Zufallsvariable X_1, \dots, X_n und $X := a_1 X_1 + \dots + a_n X_n + b$ mit $a_1, \dots, a_n, b \in \mathbb{R}$ gilt

$$\mathbb{E}[X] = a_1 \mathbb{E}[X_1] + \dots + a_n \mathbb{E}[X_n] + b$$

Def 2.35 (Indikatorvariable). Für ein Ereignis $A \subseteq \Omega$ ist die zugehörige Indikatorvariable X_A definiert durch:

$$X_A(\omega) := \begin{cases} 1, & \text{falls } \omega \in A \\ 0, & \text{sonst} \end{cases}$$

Für den Erwartungswert von X_A gilt: $\mathbb{E}[X_A] = \Pr[A]$.

Def 2.39. Für eine Zufallsvariable X mit $\mu = \mathbb{E}[X]$ definieren wir die Varianz $\text{Var}[X]$ durch:

$$\text{Var}[X] := \mathbb{E}[(X - \mu)^2] = \sum_{x \in W_X} (x - \mu)^2 \cdot \Pr[X = x]$$

Die Grösse $\sigma := \sqrt{\text{Var}[X]}$ heisst Standardabweichung von X .

Satz 2.40. Für eine beliebige Zufallsvariable X gilt

$$\text{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

Satz 2.41. Für eine beliebige Zufallsvariable X und $a, b \in \mathbb{R}$ gilt

$$\text{Var}[a \cdot X + b] = a^2 \cdot \text{Var}[X]$$

2.1 Diskrete Verteilungen

Bmk. (Bernoulli-Verteilung).

$$X \sim \text{Bernoulli}(p) \implies \mathbb{E}[X] = p \quad \text{Var}[X] = p(1 - p)$$

$$f_X(x) = \begin{cases} p & \text{für } x = 1, \\ 1 - p & \text{für } x = 0, \\ 0 & \text{sonst} \end{cases}$$

Bmk. (Binomial-Verteilung).

$$X \sim \text{Bin}(n, p) \implies \mathbb{E}[X] = np \quad \text{Var}[X] = np(1 - p)$$

$$f_X(x) = \begin{cases} \binom{n}{x} p^x (1 - p)^{n-x} & x \in \{0, 1, \dots, n\} \\ 0 & \text{sonst} \end{cases}$$

Bmk. (Negativ Binomial-Verteilung).

$$\mathbb{E}[Z] = \sum_{i=1}^n \mathbb{E}[X_i] = \frac{n}{p}$$

$$f_Z(z) = \binom{z-1}{n-1} \cdot p^n (1 - p)^{z-n}$$

Bmk. (Geometrisch-Verteilung).

$$X \sim \text{Geo}(p) \implies \mathbb{E}[X] = \frac{1}{p} \quad \text{Var}[X] = \frac{1 - p}{p^2}$$

$$f_X(i) = \begin{cases} p(1 - p)^{i-1} & \text{für } i \in \mathbb{N} \\ 0 & \text{sonst} \end{cases}$$

Satz 2.45. Ist $X \sim \text{Geo}(p)$, so gilt für alle $s, t \in \mathbb{N}$:

$$\Pr[X \geq s + t \mid X > s] = \Pr[X \geq t]$$

Bmk. (Poisson-Verteilung).

$$X \sim \text{Po}(\lambda) \implies \mathbb{E}[X] = \text{Var}[X] = \lambda$$

$$f_X(i) = \begin{cases} \frac{e^{-\lambda} \lambda^i}{i!} & \text{für } i \in \mathbb{N} \\ 0 & \text{sonst} \end{cases}$$

2.2 Mehrere Zufallsvariablen

$$\Pr[X = x, Y = y] = \Pr[\{\omega \in \Omega \mid X(\omega) = x, Y(\omega) = y\}]$$

Bmk.. Die gemeinsame Dichte von X und Y :

$$f_{X,Y}(x, y) := \Pr[X = x, Y = y]$$

$$\implies$$

$$f_X(x) = \sum_{y \in W_Y} f_{X,Y}(x, y) \text{ bzw. } f_Y(y) = \sum_{x \in W_X} f_{X,Y}(x, y)$$

Def 2.52. Zufallsvariablen X_1, \dots, X_n heißen unabhängig, genau dann wenn für alle $(x_1, \dots, x_n) \in W_{X_1} \times \dots \times W_{X_n}$ gilt

$$\Pr[X_1 = x_1, \dots, X_n = x_n] = \Pr[X_1 = x_1] \cdot \dots \cdot \Pr[X_n = x_n]$$

Lemma 2.53. Sind X_1, \dots, X_n unabhängige Zufallsvariablen und S_1, \dots, S_n beliebige Mengen mit $S_i \subseteq W_{X_i}$, dann gilt

$$\Pr[X_1 \in S_1, \dots, X_n \in S_n] = \Pr[X_1 \in S_1] \cdot \dots \cdot \Pr[X_n \in S_n]$$

Cor 2.54. Sind X_1, \dots, X_n unabhängige Zufallsvariablen und ist $I = \{i + 1, \dots, i_k\} \subseteq [n]$, dann sind X_{i_1}, \dots, X_{i_k} ebenfalls unabhängig.

Satz 2.55. Seien f_1, \dots, f_n reellwertige Funktionen ($f_i : \mathbb{R} \rightarrow \mathbb{R}$ für $i = 1, \dots, n$). Wenn die Zufallsvariablen X_1, \dots, X_n unabhängig sind, dann gilt dies auch für $f_1(X_1), \dots, f_n(X_n)$.

Satz 2.58. Für zwei unabhängige Zufallsvariablen X und Y und $Z := X + Y$. Es gilt

$$f_Z(z) = \sum_{x \in W_X} f_X(x) \cdot f_Y(z - x)$$

Satz 2.60 (Linearität des Erwartungswert). Für Zufallsvariablen X_1, \dots, X_n und $X := a_1 X_1 + \dots + a_n X_n$ mit $a_1, \dots, a_n \in \mathbb{R}$ gilt

$$\mathbb{E}[X] = a_1 \mathbb{E}[X_1] + \dots + a_n \mathbb{E}[X_n]$$

Satz 2.61 (Multiplikativität des Erwartungswerts). Für unabhängige Zufallsvariablen X_1, \dots, X_n gilt

$$\mathbb{E}[X_1 \cdot \dots \cdot X_n] = \mathbb{E}[X_1] \cdot \dots \cdot \mathbb{E}[X_n]$$

Satz 2.62. Für unabhängige Zufallsvariablen X_1, \dots, X_n und $X := a_1 X_1 + \dots + a_n X_n$ gilt

$$\text{Var}[X] = \text{Var}[X_1] + \dots + \text{Var}[X_n]$$

Satz 2.60 (Waldsche Identität). N und X seien zwei unabhängige Zufallsvariable, wobei für den Wertebereich von N gilt: $W_N \subseteq \mathbb{N}$. Weiter sei $Z := \sum_{i=1}^N X_i$ wobei X_1, X_2, \dots unabhängige Kopien von X seien. Dann gilt: $\mathbb{E}[Z] = \mathbb{E}[N] \cdot \mathbb{E}[X]$

Satz 2.67 (Ungleichung von Markov). Sei X eine Zufallsvariable, die nur nicht-negative Werte annimmt. Dann gilt für alle $t \in \mathbb{R}$ mit $t > 0$, dass

$$\Pr[X \geq t] \leq \frac{\mathbb{E}[X]}{t}$$

Oder äquivalent: $\Pr[X \geq t \cdot \mathbb{E}[X]] \leq \frac{1}{t}$

Satz 2.68 (Ungleichung von Chebyshev). Sei X eine Zufallsvariable und $t \in \mathbb{R}$ mit $t > 0$. Dann gilt

$$\Pr[|X - \mathbb{E}[X]| \geq t] \leq \frac{\text{Var}[X]}{t^2}$$

oder äquivalent: $\Pr[|X - \mathbb{E}[X]| \geq t \sqrt{\text{Var}[X]}] \leq \frac{1}{t^2}$

Satz 2.70 (Chernoff-Schranken). Seien X_1, \dots, X_n unabhängig Bernoulli verteilte Zufallsvariablen mit $\Pr[X_i = 1] = p_i$ und $\Pr[X_i = 0] = 1 - p_i$. Dann gilt für $X := \sum_{i=1}^n X_i$:

- (i) $\Pr[X \geq (1 + \delta) \mathbb{E}[X]] \leq e^{-\frac{1}{3} \delta^2 \mathbb{E}[X]} \quad \forall 0 < \delta \leq 1$
- (ii) $\Pr[X \leq (1 - \delta) \mathbb{E}[X]] \leq e^{-\frac{1}{2} \delta^2 \mathbb{E}[X]} \quad \forall 0 < \delta \leq 1$
- (iii) $\Pr[X \geq t] \leq 2^{-t} \quad \text{für } t \geq 2e \mathbb{E}[X]$

2.3 Randomisierte Algorithmen

Satz 2.72. Sei A ein randomisierter Algorithmus, der nie eine falsche Antwort gibt, aber zuweilen '???' ausgibt, wobei

$$\Pr[A(I) \text{ korrekt}] \leq \epsilon$$

Dann gilt für alle $\delta > 0$: bezeichnet man mit A_δ den Algorithmus, der A solange aufruft bis entweder ein Wert verschieden von '???' ausgegeben wird (und A_δ diesen Wert dann ebenfalls ausgibt) oder bis $N = \epsilon^{-1} \ln \delta^{-1}$ mal '???' ausgegeben wurde (und A_δ dann ebenfalls '???' ausgibt), so gilt für den Algorithmus A_δ , dass

$$\Pr[A_\delta(I) \text{ korrekt}] \geq 1 - \delta$$

Satz 2.74 (Monte Carlo - Einseitiger Fehler). Sei A ein randomisierter Algorithmus, der immer eine der beiden Antworten 'Ja' oder 'Nein' ausgibt, wobei

$$\Pr[A(I) = \text{Ja}] = 1 \text{ falls } I \text{ eine Ja-Instanz ist}$$

und

$$\Pr[A(I) = \text{Nein}] \geq \epsilon \text{ falls } I \text{ eine Nein-Instanz ist}$$

Dann gilt für alle $\delta > 0$: bezeichnet man mit $A_\delta(I)$ den Algorithmus, der A solange aufruft bis entweder der Wert 'Nein' ausgegeben wird (und A dann ebenfalls 'Nein' ausgibt) oder bis $N = \epsilon^{-1} \ln \delta^{-1}$ mal 'Ja' ausgegeben wurde (und A_δ dann ebenfalls 'Ja' ausgibt), so gilt für alle Instanzen I

$$\Pr[A_\delta(I) \text{ korrekt}] \geq 1 - \delta$$

Satz 2.75 (Monte Carlo - zweiseitiger Fehler). Sei $\epsilon > 0$ und A ein randomisierter Algorithmus, der immer eine der beiden Antworten 'Ja' oder 'Nein' ausgibt, wobei

$$\Pr[A(I) \text{ korrekt}] \geq \frac{1}{2} + \epsilon$$

Dann gilt für alle $\delta > 0$: bezeichnet man mit A_δ den Algorithmus, der $N = 4\epsilon^{-2} \ln \delta^{-1}$ unabhängige Aufrufe von A macht und dann die Mehrheit der erhaltenen Antworten ausgibt, so gilt für den Algorithmus A_δ , dass

$$\Pr[A_\delta(I) \text{ korrekt}] \geq 1 - \delta$$

Satz 2.76. Sei $\epsilon > 0$ und A ein randomisierter Algorithmus für ein Maximierungsproblem, wobei gelte:

$$\Pr[A(I) \geq f(I)] \geq \epsilon$$

Dann gilt für alle $\delta > 0$ bezeichnet man mit A_δ den Algorithmus, der $N = \epsilon^{-1} \ln \delta^{-1}$ unabhängige Aufrufe von A macht und die beste der erhaltenen Antworten ausgibt, so gilt für den Algorithmus A_δ , dass

$$\Pr[A_\delta(I) \geq f(I)] \geq 1 - \delta$$

(Für Minimierungsprobleme gilt eine analoge Aussage wenn wir „ $\geq f(I)$ “ durch „ $\leq f(I)$ “ ersetzen.)

2.3.1 Primzahltest

Satz 2.77 (Kleiner fermatscher Satz). Ist $n \in \mathbb{N}$ prim, so gilt für alle Zahlen $0 < a < n$

$$a^{n-1} \equiv 1 \pmod{n}$$

2.3.2 Target Shooting

Satz 2.79. Seien $\delta, \epsilon > 0$. Falls $N \geq 3 \frac{|U|}{|S|} \cdot \epsilon^{-2} \cdot \ln(\frac{2}{\delta})$, so ist die Ausgabe des Algorithmus TARGET-SHOOTING mit Wahrscheinlichkeit mindestens $1 - \delta$ im Intervall

$$\left[(1 - \epsilon) \frac{|S|}{|U|}, (1 + \epsilon) \frac{|S|}{|U|} \right]$$

(multiplikativer Fehler von $1 \pm \epsilon$)

Bmk. (Hashfunktion). Hashfunktion $h : U \rightarrow [m]$ mit folgenden Eigenschaften:

- h ist effizient berechenbar
- h verhält sich wie eine Zufallsfunktion, d.h.

$$\forall u \in U \forall i \in [m] : \Pr[h(u) = i] = \frac{1}{m} \quad \text{unabhängig}$$

- $s_i = s_j \implies h(s_i) = h(s_j)$

Essenz: m viel kleiner als $|U|$ für Komprimierung.

Bmk. (Kollisionen bei Hashing). Kollisionen sind neue (unerwünschte) Duplikate im Hashmap. Sei $K_{i,j}$ die Bernoulli Variable mit

$$K_{i,j} = 1 \iff (i, j) \text{ ist eine Kollision}$$

Es gilt

$$\Pr[K_{i,j} = 1] = \begin{cases} 1/m & \text{if } s_i \neq s_j, \\ 0 & \text{else} \end{cases} \implies \mathbb{E}[K_{i,j}] \leq \frac{1}{m}$$

$$\mathbb{E}[\#\text{Kollisionen}] = \sum_{1 \leq i < j \leq n} \mathbb{E}[K_{i,j}] \leq \binom{n}{2} \frac{1}{m}$$

Mit $m = n^2$ ist der Mehraufwand durch Kollisionen konstant.
Laufzeit:

$$\mathcal{O}(n) + \mathcal{O}(n \log n) + \mathcal{O}(n + |\text{Dupl}(S)|)$$